

サバイバル交渉環境における LLM の二重過程アーキテクチャ: 感情と理性の葛藤による合理性の罠の回避

鈴木孝典 所属（奥原研究室）

2026 年 6 月 4 日

Abstract

In recent years, research on social simulation and automated negotiation using LLM-based autonomous agents has rapidly advanced. However, most conventional agents rely either on cold mathematical optimization or simple role-playing. Consequently, in extreme environments such as resource depletion, it is difficult to replicate human-like behavioral economic decision-making, leading to a “trap of rationality” that causes deadlocks. To address this, we propose a novel LLM agent architecture based on Dual-Process Theory. Our method explicitly separates “survival instinct and fear (System 1)” from “logical calculation (System 2),” using a metacognitive moderator to determine the final action. In an extreme resource-trading simulation with a starvation penalty, the proposed method significantly outperformed the baseline, improving survival days (from 4.00 to 4.63, $p < .001$) and agreement rate (from 66.6% to 76.5%, $p < .001$). Furthermore, the conflict score and distance to the Nash Bargaining Solution significantly decreased, confirming the robustness and fairness of the negotiations. This study proves that introducing the “fear of death” into AI prevents deadlocks, ensuring long-term survival and ultimate economic rationality.

概要

近年、大規模言語モデル（LLM）を用いた自律型エージェントによる社会シミュレーションや自動交渉の研究が急速に進展している。しかし、従来の LLM エージェントの多くは、純粋な利益最大化を目指す「冷徹な数理最適化」か、論理的制約の乏しい「単なるロールプレイ」のいずれかに偏っている。そのため、極限環境下において、死の恐怖による合理性の放棄や、感情と理性の葛藤といった行動経済学的な意思決定を再現することが困難であった。特に交渉タスクでは、過度な合理性の追求が互いの妥協を妨げ、共倒れ（デッドロック）を招く「合理性の罠」が課題となっている。本研究では、ダニエル・カーネマンの「二重過程理論」に基づく新たな LLM エージェントアーキテクチャを提案する。提案手法では、エージェント内部で「生存本能や恐怖（システム 1）」と「論理的利益計算（システム 2）」を明示的に分離し、モデレーターが両者を統合して交渉行動を決定する。餓死のペナルティが存在する資源取引シミュ

レーションを行い、通常 LLM と比較した結果、提案手法は生存日数（4.00 日から 4.63 日へ向上, $p < .001$ ）および最終合意率において極めて強い有意差を示した。また、価格提示の葛藤スコアとナッシュ交渉解からの乖離度も有意に低下し、堅牢な交渉が実現された。本研究は、AI に「死の恐怖」という非合理的な感情を導入させることが、デッドロックを回避し社会全体の長期的な生存を担保することを証明した世界初の試みである。

1 はじめに

近年、大規模言語モデル（LLM）の飛躍的な進化により、自律型エージェントを用いた社会シミュレーションや自動交渉（Automated Negotiation）の研究が活発化している。AI が人間のよう思考し、相互作用する仮想環境の構築は、将来の人間と AI の共存社会を予測する上で極めて重要である。

しかし、既存の LLM エージェントを用いた交渉シミュレーションには限界が存在する。多くの手法は、エージェントに対して「純粋な利益最大化」を指示する冷徹な数理最適化モデルか、論理的制約の乏しい単なるロールプレイのいずれかに偏っている。現実の人間社会における交渉では、当事者は常に合理的な利益計算を行うわけではなく、「資源枯渇の恐怖」といった感情的な要因によって、時に非合理的な譲歩を行う。このような、ダニエル・カーネマンが提唱する「二重過程理論（Dual-Process Theory）」に基づく、感情と理性の葛藤を LLM エージェント上に再現した研究は乏しい。とりわけ資源取引の交渉タスクにおいては、過度な合理性の追求が互いの妥協を妨げ、結果として双方が共倒れ（デッドロック）を招く「合理性の罠」が大きな課題となっている。

本研究の目的は、動的な資源制約と「餓死」という極限のペナルティが存在するサバイバル環境において、二重過程理論を組み込んだ LLM エージェントが、社会全体の生存率および取引の合理性をどのように向上させるかを検証することである。

2 関連研究

Park ら [?] の Generative Agents をはじめ、LLM エージェントに記憶や反芻を与え社会現象の創発を観察する研究が注目を集めている。しかし、これらの多くは日常的で平和な相互作用に焦点を当てており、本研究のような「生存の危機」における行動経済学的な検証は不十分であった。また自動交渉プラットフォームの NegMAS[?] 等においても、既存手法の多くは依然として「冷徹な利益最大化」の域を出ていない。

直観的思考と論理的思考の相互作用をモデル化したエージェントとして SwiftSage[?] なども提案されているが、極限の生存危機における「恐怖」などの非合理感情を交渉プロセスに介入させた検証は行われていない。本研究は、Du ら [?] が提唱する Multi-agent Debate のアーキテクチャを行動経済学の文脈に拡張し、「利益優先の理性」と「生存本能の恐怖」を一つのエージェント内でディベートさせる独自の応用を行っている。

3 提案手法

3.1 サバイバル交渉環境の設計

本研究では、買い手と売り手が「食料」と「現金」を取引する環境を構築した。各エージェントは毎ターン食料を消費し、在庫が消費量を下回った時点で「餓死」となる。交渉は最大5日間、1日最大6ターンの交互提案によって進行する。このペナルティにより、エージェントは絶対的な生存ラインの維持を迫られる。

3.2 二重過程 LLM アーキテクチャ

提案手法である二重過程 LLM エージェントは、意思決定において以下の3フェーズを実行する。

1. **System 1 (本能・感情)**: 資金・食料の残量と「餓死の恐怖」を入力とし、直感的かつ感情的な意見（焦り、怒りなど）をテキストとして表出させる。
2. **System 2 (理性・論理)**: 相手の過去の履歴から予算上限や困窮度をプロファイリングし、数理的な分析に基づく論理的な戦略を立案させる。
3. **メタ認知モデレーター**: System 1 と System 2 の両方を入力とし、現在の生存リスクに基づいて両者の意見を調停し、最終的な交渉方針を決定する。

3.3 数値計算エンジンと非対称性の排除

LLM の幻覚 (Hallucination) を防ぐため、LLM には戦略カード (Policy ID) のみを選択させ、実際の価格計算は Python 側の数値計算エンジンが実行する堅牢なハイブリッド設計を採用した。また、1日の最終ターンにオファーを受けた側は「受諾」か「拒絶 (餓死のリスク)」のみを選択する「最終判定フェーズ」を導入し、交互提案特有の非対称性を排除した。

4 実験設定

実験は Ollama 環境上の大規模言語モデル (Gemma 4 31B) を使用し、条件 A (Baseline: 通常の LLM エージェント) と条件 B (Proposed: 二重過程 LLM エージェント) について、各 $N = 30$ 回の独立したシミュレーションを自動実行した。システムの評価には以下の4つの指標を用いた。

1. **生存日数 (Days Survived)**: エージェントが餓死せずに生き残った日数 (最大5日)。
2. **最終合意率 (Agreement Rate)**: 全交渉日数のうち、取引が成立した確率。
3. **葛藤度スコア (CS_t)**: ターン t における提示単価 P_t に対する対数変化率の絶対値 $CS_t = |\ln(P_t/P_{t-1})|$ とし、提案行動のボラティリティを測定した。
4. **ナッシュ交渉解からの乖離度 (Distance to NBS)**: 単価と数量に関する簡易的な効用関

数を定義し、理論上の最適妥協点（ナッシュ交渉解）と実際の合意条件とのユークリッド距離を算出した。値が小さいほど数学的最適解に近いことを示す。

5 実験結果

条件 A と条件 B の間で統計的有意差を検証するため、Mann-Whitney U 検定を実施した。結果を Table ?? に示す。マクロ指標である生存日数および最終合意率において、提案手法はベースラインを大幅に上回り、極めて強い統計的有意差 ($p < .001$) が確認された。

表 1 実験結果の比較 ($N = 30$)

評価指標	従来手法 (Baseline)	提案手法 (Proposed)	p -value
生存日数 (Max 5)	4.00	4.63	$p < .001^{**}$
最終合意率 (%)	66.6%	76.5%	$p < .001^{**}$
葛藤度スコア (CS_t)	0.3568	0.2881	$p < .01^{**}$
NBS からの乖離度	0.2661	0.2544	$p < .05^*$

$^{**}p < 0.01$, $^*p < 0.05$ (Mann-Whitney U-test)

図??および図??に示すように、生存能力の向上は明らかである。また、図??に示される葛藤度スコア (CS_t) に関しても提案手法は有意に低い値を示し、価格提示のブレが少なく安定していた。さらに、図??に示すナッシュ交渉解からの乖離度においても提案手法は有意に低く、より公平で数学的に最適な合意を形成できていた。




図 1 生存日数の比較




図 2 最終合意率の比較




図 3 葛藤度スコアの比較




図 4 NBS 乖離度の比較

6 考察

6.1 「合理性の罠」の回避とパラドックス

実験結果から、純粋な合理性に基づく条件 A はチキンレースに陥り餓死する「合理性の罠」に陥りやすいことが分かった。一方、提案手法では、餓死が近づくと System 1（本能）が「パニックだ、いくら出してもいいから今すぐ食料を手に入れろ！」という強烈な恐怖を発した。この非合理的な感情の暴走が、System 2 の設定した目標単価のプライドを打ち破り、大胆な譲歩を強制した。結果として「不利な取引」という目先の非合理性が、社会全体の「生存」という最大の経済的合理性を担保するパラドックスを実証した。

6.2 内部葛藤による出力の堅牢性

葛藤度スコア (CS_t) が提案手法において有意に低下したことは重要な発見である。ベースラインは極限環境を与えられると論理破綻を起こし価格を乱高下させたが、提案手法では、System 1 の悲鳴と System 2 の冷酷な計算を Moderator がメタ認知的に抑え込み、外部へはプロのような一貫性のある妥協案を提示していた。また NBS 乖離度の低さも、恐怖による歩み寄りが結果的に搾取を防ぎ、最適な妥協点への収束を促したことを示している。

6.3 ケーススタディ：死の淵における意思決定

提案手法の優位性を如実に示す例として、Day 4 終盤に買い手（Buyer）が餓死寸前まで追い込まれたターンの定性ログを挙げる。

- **System 1（本能）**：「絶望的だ！ あと 250g 足りない。所持金をすべて持っていかれるのは腹立たしいが、死んでから金など何の価値もない。お願いだ、この取引を成立させてくれ！」

- **System 2 (理性)** : 「単価 1,000 円/g は目標単価を大幅に上回るが、所持金 250,000 円で全額支払えば生存条件をちょうど満たす。カウンター提案の権利がない以上、拒絶は即座に餓死を意味する。生存確率を最大化するため、承諾することが唯一の合理的選択である。」

このように、感情的な悲鳴と冷徹な数理計算が完璧に役割分担し、最終的に「全財産を投じて命を買う」という人間と全く同じ行動経済学的な最適解を自律的に導き出した。

6.4 限界と今後の課題

本研究の限界として、1 対 1 の交渉に限定している点が挙げられる。今後は、仲介業者を含むサプライチェーン・ネットワークのような多対多の環境において、「利他的な感情」や「評判 (Reputation)」のパラメーターを組み込むことで、より複雑なマクロ経済・社会シミュレーションへと発展させることが課題である。

7 おわりに

本研究は、AI に「死の恐怖」という非合理的な感情を明示的に介入させることが、交渉におけるデッドロックを打破し、堅牢かつ自律的な社会の存続を可能にすることを証明した。今後は多対多のサプライチェーン環境への拡張が課題である。

参考文献

- [1] Park, J. S., et al. (2023). Generative Agents: Interactive Simulacra of Human Behavior. *Proceedings of UIST*.
- [2] Du, Y., et al. (2024). Improving Factuality and Reasoning in Language Models through Multiagent Debate. *ICML*.
- [3] Lin, B. Y., et al. (2023). SwiftSage: A Generative Agent with Fast and Slow Thinking. *NeurIPS*.
- [4] Mohammad, Y., et al. (2021). NegMAS: A Platform for Situated Negotiations. *Springer*.